



DIPARTIMENTO DI MATEMATICA E APPLICAZIONI
CORSO DI LAUREA IN MATEMATICA
A.A.2020/21

TESI DI LAUREA

La Legge di Benford

CANDIDATA
Sara Cambiaghi

RELATORE
Francesco Caravenna

MATRICOLA: 839725

Indice

1	Introduzione	1
2	Preliminari	3
2.1	Catene di Markov	3
2.2	Indice di Correlazione di Pearson	4
2.3	Test di Kolmogorov-Smirnov	5
3	Possibili spiegazioni	7
3.1	Primo Approccio	7
3.2	Secondo Approccio	10
4	Catene di Markov e invarianza di scala	17
4.1	Distribuzione delle prime m cifre	17
4.2	Costruzione della catena di Markov	19
4.3	Probabilità invarianti per la Catena di Markov	21
5	Applicazioni della legge di Benford	23
5.1	Social Network	23
5.1.1	Introduzione	23
5.1.2	Raccolta dei Dati / Campionamento	24
5.1.3	Risultati	24
5.1.4	Conclusioni	26
5.1.5	Applicazioni future	28
5.2	Covid-19	28
	Bibliografia	31

Capitolo 1

Introduzione

Questa tesi tratterà la **legge di Newcomb-Benford**, conosciuta anche come **legge della prima cifra**, un risultato che ha come oggetto la distribuzione delle prime cifre significative dei numeri reali, e quindi delle loro mantisse.

Definiamo la **mantissa** di un numero reale positivo x come l'unico numero reale $m(x) \in [1, 10)$ tale che

$$x = m(x) \cdot 10^k$$

per qualche intero $k \in \mathbb{Z}$. Più esplicitamente, $m(x) \in [1, 2)$ se $x \in \bigcup_{k \in \mathbb{Z}} [10^k, 2 \cdot 10^k) = [1, 2) \cup [10, 20) \cup [100, 200) \cup \dots \cup [0.1, 0.2) \cup [0.01, 0.02) \cup \dots$. La parte intera $[m(x)]$ della mantissa rappresenta la *prima cifra significativa* di x . Quello che ci si potrebbe aspettare è che le nove cifre compaiano come prime cifre significative con la stessa frequenza, ovvero circa $\frac{1}{9}$ delle volte. Osservando dati sperimentali provenienti da molteplici fonti del mondo reale notiamo che questo molto spesso *non* si verifica.

La distribuzione che si osserva è invece:

$$P_{Benford}([a, b)) = P(m(x) \in [a, b)) = \log_{10} b - \log_{10} a. \quad (1.1)$$


che, riformulata, equivale a

$$P_{Benford}([i, i+1)) = P(m(x) \in [i, i+1)) = \log_{10} \left(\frac{i+1}{i} \right) = \log_{10} \left(1 + \frac{1}{i} \right). \quad (1.2)$$

Con un calcolo esplicito possiamo dedurre che, in base a questa legge, 1 dovrebbe comparire come prima cifra significativa circa il 30,1% delle volte, i numeri successivi in una percentuale minore fino a 9, che compare il 4,6% delle volte.

Questo fenomeno fu osservato per la prima volta verso la fine del diciannovesimo secolo dall'astronomo e matematico Simon Newcomb che, consultando alcune tavole dei logaritmi, notò che le prime pagine erano più consumate rispetto alle ultime, e questo lo condusse alla conclusione che agli utenti capitava più frequentemente di dover cercare numeri la cui prima cifra era bassa piuttosto che alta. Newcomb decise di pubblicare la sua scoperta in un articolo di due pagine, dal titolo "*Note on the frequency of use of different digits in natural numbers*" (1881). 57 anni più tardi il fisico e ingegnere Frank Benford, ignaro dello scritto del suo predecessore, fece la stessa osservazione e pubblicò un articolo di 22 pagine dal titolo "*The law of the*

anomalous numbers" (1938), contenente una spiegazione matematica di (1.2) e venti tabelle, con complessivamente più di 20 000 prime cifre significative estrapolate dai contesti più disparati: aree di fiumi, popolazioni delle città americane, costanti fisiche, e alcune successioni come n^{-1} , $\sqrt{n}$, n^2 , $n!$ per $n \in [1, 100]$. Grazie alla completezza di questo secondo lavoro spesso la legge viene chiamata semplicemente *Legge di Benford*, tralasciando il nome del suo precursore.



Simon Newcomb (1835-1909)



Frank Benford (1883-1948)

È necessario osservare che la legge di Benford *non è universale*, bensì è una proprietà che appare in specifici contesti, anche se molto numerosi.

Una caratteristica sorprendente è l'*invarianza di scala*: se un elenco di dati segue la legge di Benford, allora la segue con qualsiasi unità di misura. Prendiamo ad esempio un elenco di lunghezze: se seguono la distribuzione logaritmica quando vengono espresse in chilometri, allora continueranno a seguirla anche se le esprimiamo in miglia o in qualsiasi altra unità di misura.

Questa tesi tratterà tre argomenti:

- In primo luogo cercheremo di dare una spiegazione teorica della legge di Benford, analizzando due dei vari approcci possibili:
 - un approccio probabilistico;
 - la prova data da Raimi, che stima la probabilità $p(r)$ che la mantissa di un numero naturale scelto in opportuno modo casuale sia minore di r .
- Ci baseremo sull'invarianza di scala della distribuzione della mantissa per costruire una catena di Markov e ne calcoleremo la probabilità invariante. Giungeremo alla conclusione che, sotto opportune ipotesi, tale probabilità è unica e coincide con la legge di Benford.
- Mostreremo due applicazioni concrete della legge di Newcomb-Benford:
 - analizzeremo il numero di amici e di post degli utenti di alcuni Social Network, per capire se la legge può essere utile allo scopo di individuare account fraudolenti;
 - analizzeremo il numero di nuovi positivi al Covid-19 in Italia giorno per giorno, verificando se i valori si comportano come predetto dalla legge di Benford.

Capitolo 2

Preliminari

Per cominciare, introduciamo alcuni risultati che verranno richiamati in seguito. Quanto detto è stato tratto dai libri *Introduzione alla Statistica* [6] e *Probabilità. Un primo corso attraverso esempi, modelli e applicazioni* [3].

2.1 Catene di Markov

Richiamiamo alcuni dei risultati fondamentali riguardanti le catene di Markov.

Definizione 2.1.1. (Processo Stocastico) Si dice **Processo Stocastico** una famiglia di variabili aleatorie $(X_i)_{i \in \mathbb{N}}$ definite sullo stesso spazio di probabilità $(\Omega, \mathcal{A}, P)$ a valori nello stesso spazio di misura $(E, \mathcal{E})$.

Possiamo pensare a $X = (X_n)_{n \geq 0}$ come ad un moto aleatorio nell'insieme E , quindi X_n rappresenta la posizione al tempo n .

Definizione 2.1.2. (Catena di Markov) Un processo stocastico $X = (X_n)_{n \geq 0}$ con spazio degli stati E finito o numerabile si dice **Catena di Markov (omogenea)** se esiste $q : E \times E \rightarrow \mathbb{R}$ tale che valga la seguente **proprietà di Markov**:

$$P(X_{n+1} = y | X_n = x, X_{n-1} = x_{n-1}, \dots, X_0 = x_0) = P(X_{n+1} = y | X_n = x) = q(x, y)$$

$\forall n \geq 0, \forall x_0, x_1, \dots, x_{n-1}, x, y \in E$. $Q = (q(x, y))_{x, y \in E}$ è detta **Matrice di Transizione** della catena di Markov, e si scrive $X = (X_n)_{n \geq 0} \sim \text{Markov}(Q)$.

La matrice di transizione descrive la *Probabilità di Salto*. In una catena di Markov, conoscendo X_n , possiamo determinare la distribuzione di X_{n+1} indipendentemente da $X_0, X_1, \dots, X_{n-1}$.

Definizione 2.1.3. (Catena Irriducibile) Sia $X = (X_n)_{n \geq 0} \sim \text{Markov}(Q)$ su E . Dati $x, y \in E$ diciamo che **y è accessibile da x** se esiste $m \geq 0$ tale che

$$Q^m(x, y) = P(X_m = y | X_0 = x) > 0$$

Diciamo che x e y **comunicano** se y è accessibile da x e x è accessibile da y . Se tutti gli stati comunicano diciamo che la catena è **Irriducibile**.

Definizione 2.1.4. (Misura Stazionaria) Una misura $\lambda = (\lambda(x))_{x \in E}$ si dice **Stazionaria** o **Invariante** per la catena di Markov $X \sim \text{Markov}(Q)$ se soddisfa

$$\lambda^T = \lambda^T Q$$

ossia

$$\lambda(y) = \sum_{x \in E} \lambda(x) q(x, y)$$

$\forall y \in E$. Se λ è una probabilità, ovvero soddisfa $\sum_{x \in E} \lambda(x) = 1$, diremo che è una **probabilità (o distribuzione) stazionaria**.

Se la distribuzione iniziale della catena di Markov è stazionaria, allora la distribuzione all'istante X_m non dipende da m ma coincide con quella iniziale: la distribuzione stazionaria descrive una condizione di equilibrio per la catena.

Lemma 2.1.1. Se $X = (X_n)_{n \geq 0} \sim \text{Markov}(Q)$ è una catena di Markov irriducibile su E finito, allora esiste unica la distribuzione stazionaria.

Definizione 2.1.5. (Periodo) Sia $x \in E$ uno stato. Si definisce **periodo** di x la quantità

$$t_x = \text{MCD}\{n \in \mathbb{N} \mid Q^n(x, x) > 0\}$$

Se $t_x=1$ lo stato si dice **aperiodico**.

Lemma 2.1.2. Se x e y comunicano hanno lo stesso periodo, quindi se la catena è irriducibile tutti i suoi stati hanno lo stesso periodo, detto periodo della catena.

Lemma 2.1.3. (Comportamento asintotico) Sia $X = (X_n)_{n \geq 0}$ una catena di Markov irriducibile su E finito. Se assumiamo che X sia aperiodica, allora vale

$$\lim_{n \rightarrow \infty} P_x(X_n = y) = \lambda(y)$$

$\forall x, y \in E$, dove λ è l'unica distribuzione stazionaria della catena.

2.2 Indice di Correlazione di Pearson

L'indice di correlazione di Pearson è un indice del grado di correlazione *lineare* tra X e Y .

Definizione 2.2.1. (Indice di Correlazione) Date due variabili aleatorie X e Y , denotiamo con σ_{XY} la covarianza tra X e Y e con σ_X, σ_Y le deviazioni standard di X e Y rispettivamente. L'indice di correlazione di Pearson è definito come

$$\rho_{XY} = \frac{\sigma_{XY}}{\sigma_X \cdot \sigma_Y}$$

ammesso che σ_{XY} , σ_X e σ_Y esistano, e che $\sigma_X > 0$, $\sigma_Y > 0$.

2.3 Test di Kolmogorov-Smirnov

Il **Test di Kolmogorov-Smirnov** è un test non parametrico usato per confrontare un campione con una distribuzione di riferimento o per confrontare due campioni tra di loro.

Data una variabile aleatoria X , ci chiediamo se la sua funzione di ripartizione $F(x)$ è uguale a una data $F_0(x)$. Scegliamo come ipotesi nulla $H_0 : F(x) = F_0(x)$ per ogni x , e come ipotesi alternativa $H_1 : F(x) \neq F_0(x)$ per almeno una x .

Sia $(X_1, \dots, X_n)$ un campione casuale di ampiezza n . Definiamo la *funzione di ripartizione campionaria* $\hat{F}_n(x) = \frac{1}{n} \cdot (\text{numero degli } X_i \text{ minori o uguali a } x)$; più esplicitamente:

$$\hat{F}_n(x) = \begin{cases} 0 & \text{se } x \leq X(1) \\ \frac{k}{n}, & \text{se } X(k) \leq x < X(k+1) \\ 1, & \text{se } x \geq X(n) \end{cases}$$

dove $X(1), \dots, X(n)$ sono le n variabili campionarie in ordine crescente. Possiamo scrivere $\hat{F}_n(x) = \frac{1}{n} \sum_{k=1}^n \mathbb{1}_{\{X_k \leq x\}}$.

$\hat{F}_n(x)$ è una statistica perché è una funzione del campione, e per il *Teorema Limite Centrale* è asintoticamente distribuita come una normale con media $F(x)$ e varianza $\frac{1}{n} F(x)[1 - F(x)]$. Inoltre $\hat{F}_n(x)$ è uno stimatore non distorto e consistente in media quadratica di $F(x)$. Ricordiamo che uno stimatore T di $\tau(\theta)$ è detto non distorto se $E_\theta[T] = \tau(\theta)$ per tutti i θ nello spazio dei parametri, mentre una successione di stimatori T_n di $\tau(\theta)$ è consistente in media quadratica se $\lim_{n \rightarrow \infty} E_\theta[[T_n - \tau(\theta)]^2] = 0$ per tutti i θ nello spazio dei parametri.

Definiamo la distanza

$$D_n = \sup_{-\infty < x < \infty} |\hat{F}_n(x) - F_0(x)|$$

detta *statistica di Kolmogorov*. Per valori “grandi” di D_n l’ipotesi nulla verrà rifiutata, mentre la si accetterà per valori “piccoli”. Quanto grande deve essere il valore di D_n affinché l’ipotesi nulla venga rifiutata dipende dal livello di significatività $\alpha \in [0, 1]$ che scegliamo, ovvero dalla massima probabilità che tolleriamo di rifiutare un’ipotesi nulla vera.

Capitolo 3

Possibili spiegazioni

Molti autori si sono cimentati nella ricerca di una possibile spiegazione della legge di Benford, adoperando gli approcci più disparati.

In questo capitolo ne analizzeremo due: in un primo momento tratteremo un approccio probabilistico, basato sull'ipotesi che la distribuzione della mantissa sia universale.

Successivamente analizzeremo la prova data da Ralph A. Raimi, in cui viene stimato il valore di $p(r)$, che rappresenta la probabilità che la mantissa di un numero naturale scelto in opportuno modo casuale sia minore di un dato valore r .

In entrambi i casi ritroveremo la distribuzione logaritmica precedentemente introdotta. Questi risultati forniscono una giustificazione teorica, sotto opportune ipotesi, della *Legge di Benford*.

3.1 Primo Approccio

Questa sezione è tratta dal testo *Probabilità. Un primo corso attraverso esempi, modelli e applicazioni* [3].

Dato un numero reale $x \in \mathbb{R}$, esso può essere scritto come $x = m(x) \cdot 10^k$ per un certo $k \in \mathbb{Z}$, dove $m(x)$ è la *mantissa* di x , compresa tra $[1, 10)$. Supponiamo che la distribuzione della mantissa sia universale, ovvero che sia la stessa per ogni elenco di dati esistente; questa sarà l'ipotesi fondamentale che ci permetterà di giungere alla distribuzione cercata. In particolare questo implica che se cambiamo unità di misura, la legge della mantissa non cambia: la distribuzione di $m(x)$ è la stessa di $m(cx)$, per ogni c positivo.

Consideriamo il seguente esperimento aleatorio: sia dato un ampio elenco di dati da cui estraiamo casualmente un valore X . Vogliamo determinare la distribuzione della mantissa di X , $m(X)$. Per semplicità consideriamo la variabile aleatoria

$$Y = \log_{10}(m(X))$$

L'obiettivo, in un primo momento, sarà quello di determinare la funzione di ripartizione di Y . Notiamo innanzitutto che $m(X) \in [1, 10) \Rightarrow Y \in [0, 1)$, di conseguenza F_Y è nulla prima di zero e identicamente uguale a 1 dopo 1. Osserviamo che

$$X = m(X) \cdot 10^k \iff \log_{10} X = \log_{10}(m(X)) + k = Y + k$$

quindi $k = \lfloor \log_{10} X \rfloor$ e $Y = \{\log_{10} X\}$, dove $[x]$ indica la parte intera di x e $\{x\} = x - [x]$ indica la parte frazionaria di x . L'ipotesi fatta inizialmente si traduce nella richiesta che la distribuzione di $Y_c = \log_{10}(m(cX))$ coincida con quella di Y . Per definizione

$$Y_c = \{\log_{10}(cX)\} = \{\log_{10} X + \log_{10} c\} = \{Y + \log_{10} c\}$$

e ponendo $b = -\log_{10} c \in \mathbb{R}$ otteniamo

$$P(Y_c \in [s, t]) = P(\{Y - b\} \in [s, t])$$

per ogni $0 \leq s < t < 1$ e per ogni $b \in \mathbb{R}$. Per ipotesi abbiamo supposto che la distribuzione di Y_c coincide con quella di Y , quindi:

$$P(Y \in [s, t]) = P(\{Y - b\} \in [s, t]) = P(Y \in [s + b, t + b] \bmod 1) \quad (3.1)$$

Dove $\bmod 1$ è definito nel seguente modo:

$$[s + b, t + b] \bmod 1 = \begin{cases} [s + b, t + b], & \text{se } 0 \leq s + b < t + b < 1 \\ [s + b, 1) \cup [0, t + b - 1), & \text{se } 0 \leq s + b < 1 < t + b < 2 \\ [s + b - 1, t + b - 1), & \text{se } 1 \leq s + b < t + b < 2 \end{cases}$$

se consideriamo $b \in [0, 1)$ (se $b \geq 1$ è analogo). Questo ci porta alla conclusione che $P(Y \in [s, t] \bmod 1)$ dipende solo dalla lunghezza di $[s, t]$ e non dalla sua posizione: traslando l'intervallo la probabilità che Y ci cada rimane invariata.

Lemma 3.1.1. *Una variabile aleatoria Y a valori in $[0, 1)$ soddisfa la proprietà (3.1) se e solo se Y ha distribuzione $U(0, 1)$.*

Dimostrazione. Supponiamo $Y \sim U(0, 1)$; presi $0 \leq s < t < 1$ sappiamo che $P(Y \in [s, t]) = t - s$. Questo è sufficiente per concludere che (3.1) vale, infatti:

- se $0 \leq s + b < t + b < 1 \Rightarrow [s + b, t + b] \bmod 1 = [s + b, t + b)$, quindi $P(Y \in [s + b, t + b]) = t + b - (s + b) = t - s = P(Y \in [s, t])$
- se $0 \leq s + b < 1 < t + b < 2 \Rightarrow [s + b, t + b] \bmod 1 = [s + b, 1) \cup [0, t + b - 1)$, quindi $P(Y \in [s + b, 1) \cup [0, t + b - 1)) = 1 - (s + b) + t + b - 1 = t - s = P(Y \in [s, t])$
- se $1 \leq s + b < t + b < 2 \Rightarrow [s + b, t + b] \bmod 1 = [s + b - 1, t + b - 1)$, quindi $P(Y \in [s + b - 1, t + b - 1)) = t + b - 1 - (s + b - 1) = t - s = P(Y \in [s, t])$

Supponiamo, viceversa, che Y sia una variabile aleatoria a valori in $[0, 1)$ che soddisfa (3.1). Per quanto detto precedentemente questo implica che il traslato di un intervallo ha probabilità uguale a quella dell'intervallo stesso. Considerando $[s, t) = [0, \frac{1}{n})$ e $b = \frac{k-1}{n}$ per ogni $n \in \mathbb{N}$ e $1 \leq k \leq n$ otteniamo

$$P(Y \in [0, \frac{1}{n})) = P(Y \in [\frac{k-1}{n}, \frac{k}{n}))$$

ma

$$1 = P(Y \in [0, 1)) = \sum_{k=1}^n P(Y \in [\frac{k-1}{n}, \frac{k}{n}))$$

perché Y assume valori in $[0, 1)$. Inoltre, per l'ipotesi fatta inizialmente, tutti i termini che compaiono nella sommatoria assumono lo stesso valore, quindi

$$P(Y \in [\frac{k-1}{n}, \frac{k}{n})) = \frac{1}{n}.$$

Consideriamo ora $r \in [0, 1) \cap \mathbb{Q}$; possiamo scrivere r come $\frac{k}{n}$ per qualche $n \geq 1$ e $1 \leq k \leq n$ e affermare che

$$P(Y \in [0, r)) = \sum_{i=1}^k P(Y \in [\frac{i-1}{n}, \frac{i}{n})) = k \cdot \frac{1}{n} = r$$

Sia $t \in (0, 1)$ arbitrario e $r_1, r_2 \in \mathbb{Q}$ tali che $0 < r_1 \leq t < r_2 < 1$. Abbiamo che

$$r_1 = P(Y \in [0, r_1)) \leq P(Y \in [0, t]) \leq P(Y \in [0, r_2)) = r_2.$$

e scegliendo r_1 e r_2 arbitrariamente vicini a t possiamo concludere che $P(Y \in [0, t]) = t$ per ogni $t \in (0, 1)$. In particolare $P(Y = 0) = 0$, in quanto $P(Y = 0) \leq P(Y \in [0, \epsilon]) = \epsilon$ e ϵ può essere resa piccola a piacere. Considerando infine che $Y \in [0, 1)$ per ipotesi, possiamo concludere che la sua funzione di ripartizione vale:

$$F_Y(t) = P(Y < t) \begin{cases} 0, & \text{se } t < 0 \\ t, & \text{se } t \in [0, 1) \\ 1, & \text{se } t \geq 1 \end{cases} \quad (3.2)$$

e corrisponde quindi alla funzione di ripartizione di una variabile aleatoria con distribuzione $U(0, 1) \Rightarrow Y \sim U(0, 1)$. $\square$

A questo punto non ci resta che ricavare la funzione di ripartizione della mantissa di X , $m(X) = 10^Y$. Notiamo che la funzione che manda $x \mapsto \log_{10} x$ è strettamente crescente, quindi l'evento $\{m(X) = 10^Y \leq t\}$ corrisponde a $\{Y \leq \log_{10} t\}$. Sappiamo inoltre che $m(X)$ assume valori in $[1, 10)$, quindi, applicando (3.2), possiamo concludere che:

$$F_{m(X)}(t) = \begin{cases} 0, & \text{se } t < 1 \\ \log_{10} t, & \text{se } 1 \leq t < 10 \\ 1, & \text{se } t \geq 10 \end{cases} \quad (3.3)$$

Questa funzione è continua su $\mathbb{R}$ e $\mathcal{C}^1$ a tratti, il che implica che $m(X)$ è una variabile aleatoria assolutamente continua con densità

$$f_{m(X)}(x) = F'_{m(X)}(x) = \frac{1}{x \log 10} \mathbb{1}_{[1, 10)}(y) \quad (3.4)$$

Questa distribuzione è detta *legge di Benford continua*. Usiamo la densità appena trovata per calcolare la probabilità con cui le cifre compaiono come prime cifre significative. Riconsideriamo la variabile aleatoria X introdotta inizialmente e definiamo $Z = [m(X)]$. Z rappresenta la parte intera della mantissa di X , ovvero la prima cifra significativa di $X = m(X) \cdot 10^k$, e può valere 1, 2, 3, 4, 5, 6, 7, 8 oppure 9; in particolare $\{Z = k\} \Leftrightarrow \{m(X) \in [k, k+1)\}$:

$$P(Z = k) = P(m(X) \in [k, k+1)) = \int_k^{k+1} \frac{1}{x \log 10} dx = \frac{\log(k+1)}{\log 10} - \frac{\log k}{\log 10}$$

dove nella seconda uguaglianza abbiamo usato (3.4). Concludiamo quindi che

$$p_Z(k) = P(Z = k) = \log_{10} \left(\frac{k+1}{k} \right) \quad (3.5)$$

per ogni $k \in \{1, 2, 3, 4, 5, 6, 7, 8, 9\}$. La distribuzione di Z è detta *legge di Benford discreta*. Ne riportiamo i valori nella seguente tabella:

k	1	2	3	4	5	6	7	8	9
$p_Z(k)$	0.301	0.176	0.125	0.097	0.079	0.067	0.058	0.051	0.046

3.2 Secondo Approccio

Quanto detto in questa sezione è stato tratto da *The Art Of Computer Programming, Vol.2* di D.E.Knuth [1], pagina 254-262.

Consideriamo un numero naturale $n \in \mathbb{N}$; anche in questo caso il valore può essere scritto come $n = 10^k \cdot m(n)$. Sia $r \in [1, 10]$ un numero reale fissato; vogliamo calcolare la probabilità $p(r)$ che $m(n) < r$, per un certo $n \in \mathbb{N}$ scelto casualmente. Il problema è che non è possibile scegliere n in modo casuale tra tutti i numeri naturali, quindi, fissato un valore t , definiamo

$$P_0(t) = \mathbb{1}_{\{t=10^k \cdot m(t) \mid m(t) < r\}} = \mathbb{1}_{\{(\log_{10} t) \bmod 1 < \log_{10} r\}} \quad (3.6)$$

Così $P_0(1), P_0(2) \dots$ è una sequenza infinita di 0 e 1 (in particolare $P_0(i)$ vale 1 in caso $m(i) < r$, e quindi i contribuisce a $p(r)$, 0 in caso contrario), di cui possiamo “fare la media” nel seguente modo:

$$P_1(t) = \frac{1}{t} \sum_{k=1}^t P_0(k) \quad (3.7)$$

Possiamo ora considerare un valore n estratto casualmente tra 1 e t , e concludiamo che la probabilità che $m(n) < r$ è esattamente $P_1(t)$. A noi interessa un valore estratto casualmente in $\mathbb{N}$, quindi è naturale definire $p(r)$ come il $\lim_{t \rightarrow \infty} P_1(t)$, in questo modo l'intervallo $[1, t]$ in cui è estratto casualmente n tende da $[1, \infty)$. Notiamo però che in questo caso tale limite non esiste. Per esempio, dato $s \in [1, 10]$ numero reale, possiamo considerare la seguente sottosuccessione:

$$P_1(s), P_1(10s), P_1(100s), \dots, P_1(10^n s)$$

Abbiamo che, se $1 \leq s \leq r$

$$\begin{aligned} P_1(10^n s) &= \frac{1}{10^n s} \sum_{k=1}^{10^n s} P_0(k) = \frac{1}{10^n s} \left[\sum_{k=1}^{10} P_0(k) + \sum_{k=10}^{100} P_0(k) + \dots + \sum_{k=10^{n-1}}^{10^n} P_0(k) + \sum_{k=10^n}^{10^n s} P_0(k) \right] \\ &= \frac{1}{10^n s} (\lceil r \rceil - 1 + \lceil 10r \rceil - 10 + \dots + \lceil 10^{n-1} r \rceil - 10^{n-1} + \lfloor 10^n s \rfloor + 1 - 10^n) \end{aligned}$$

dove $\lceil x \rceil$ indica il più piccolo intero $k \geq x$ e $\lfloor x \rfloor$ indica il più grande intero $k \leq x$. La formula vale perché se $k \in [10^i, 10^{i+1})$ la mantissa di k sarà minore di quella di r $\lceil 10^i r \rceil - 10^i$ volte, mentre se $k \in [10^n, 10^n s)$ la sua mantissa sarà sicuramente minore o uguale a r , perché per

ipotesi $s \leq r$. Sommando otteniamo che

$$\begin{aligned}
& \frac{1}{10^n s} (\lceil r \rceil - 1 + \lceil 10r \rceil - 10 + \dots + \lceil 10^{n-1} r \rceil - 10^{n-1} + \lfloor 10^n s \rfloor + 1 - 10^n) \\
&= \frac{1}{10^n s} (r(1 + 10 + \dots + 10^{n-1}) + O(n) + \lfloor 10^n s \rfloor - 1 - 10 - \dots - 10^n) \\
&= \frac{1}{10^n s} (r \cdot \frac{10^n - 1}{9} + O(n) + \lfloor 10^n s \rfloor - \frac{10^{n+1} - 1}{9}) \\
&= \frac{1}{10^n s} (\frac{1}{9}(10^n r - 10^{n+1}) + O(n) + \lfloor 10^n s \rfloor)
\end{aligned} \tag{3.8}$$

dove nella seconda uguaglianza abbiamo usato che

$$\sum_{n=0}^k q^n = \frac{1 - q^{k+1}}{1 - q} \tag{3.9}$$

e, data $f(x)$ una funzione definita su qualche sottoinsieme dei numeri reali, diciamo che $f(x) \in O(x)$ per $x \rightarrow \infty$ se e solo se esiste $x_0 \in \mathbb{R}$, $c > 0$: $|f(x)| \leq c \cdot x$ per ogni $x \geq x_0$. Il termine $O(n)$ controlla quindi l'errore nel momento in cui si approssima la parte intera con il valore effettivo, perché i due distano al più una unità. Possiamo quindi concludere che per $n \rightarrow \infty$, $P_1(10^n s) \rightarrow 1 + \frac{r-10}{9s}$. Allo stesso modo, se $s > r$,

$$\begin{aligned}
P_1(10^n s) &= \frac{1}{10^n s} \sum_{k=1}^{10^n s} P_0(k) = \frac{1}{10^n s} [\sum_{k=1}^{10} P_0(k) + \sum_{k=10}^{100} P_0(k) + \dots + \sum_{k=10^{n-1}}^{10^n} P_0(k) + \sum_{k=10^n}^{10^n s} P_0(k)] \\
&= \frac{1}{10^n s} (\lceil r \rceil - 1 + \lceil 10r \rceil - 10 + \dots + \lceil 10^{n-1} r \rceil - 10^{n-1} + \lceil 10^n r \rceil - 10^n) \\
&= \frac{1}{10^n s} (r(1 + 10 + \dots + 10^n) + O(n) - 1 - 10 - \dots - 10^n) \\
&= \frac{1}{10^n s} (r \cdot \frac{10^{n+1} - 1}{9} + O(n) - \frac{10^{n+1} - 1}{9}) \\
&= \frac{1}{10^n s} (\frac{1}{9}(10^{n+1} r - 10^{n+1}) + O(n))
\end{aligned} \tag{3.10}$$

In questo caso però, per $n \rightarrow \infty$, $P_1(10^n s) \rightarrow \frac{10(r-1)}{9s}$. La sottosuccessione oscilla dunque tra i valori trovati, e questo è sufficiente per affermare che il limite non esiste. Per risolvere questo problema possiamo riapplicare (3.7) e definire ricorsivamente, $\forall m \in \mathbb{N}$:

$$P_{m+1}(n) = \frac{1}{n} \sum_{k=1}^n P_m(k)$$

con la speranza che all'aumentare di m il comportamento oscillatorio della successione venga smorzato. Dimostriamo a questo scopo il seguente lemma:

Lemma 3.2.1. *Per ogni $m \geq 1$ e ogni $\epsilon > 0$, esistono funzioni $Q_m(s)$, $R_m(s)$ e un intero $N_m(\epsilon)$ tali che, quando $n > N_m(\epsilon)$ e $1 \leq s \leq 10$, vale che:*

$$|P_m(10^n s) - Q_m(s) - R_m(s) \mathbb{1}_{\{s > r\}}| < \epsilon \tag{3.11}$$

dove

$$\begin{aligned}
Q_m(s) &= \frac{1}{s} \left[\frac{1}{9} \int_1^{10} Q_{m-1}(t) dt + \int_1^s Q_{m-1}(t) dt + \frac{1}{9} \int_r^{10} R_{m-1}(t) dt \right]; \\
Q_0(s) &= 1; \\
R_m(s) &= \frac{1}{s} \int_r^s R_{m-1}(t) dt; \\
R_0(s) &= -1;
\end{aligned} \tag{3.12}$$

Dimostrazione. Consideriamo $Q_m(s)$ e $R_m(s)$ definite in (3.12), e definiamo

$$S_m(t) = [Q_m(t) + R_m(t)] \mathbb{1}_{\{t > r\}} \tag{3.13}$$

Proveremo il lemma procedendo per induzione su m . Iniziamo quindi considerando il caso base $m = 1$:

$$\begin{aligned}
Q_1 &= \frac{1}{s} \left(\frac{1}{9} \int_1^{10} Q_0(t) dt + \int_1^s Q_0(t) dt + \frac{1}{9} \int_r^{10} R_0(t) dt \right) \\
&= \frac{1}{s} \left(\frac{1}{9} \int_1^{10} 1 dt + \int_1^s 1 dt - \frac{1}{9} \int_r^{10} 1 dt \right) \\
&= \frac{1}{s} \left(\frac{1}{9} \cdot 9 + (s-1) - \frac{10-r}{9} \right) \\
&= 1 + \frac{r-10}{9s}
\end{aligned}$$

$$R_1(s) = \frac{1}{s} \int_r^s R_0(t) dt = -\frac{1}{s} \int_r^s 1 dt = -\frac{r-s}{s}$$

e usando (3.10) otteniamo:

$$\begin{aligned}
|P_1(10^n s) - S_1(s)| &= \frac{1}{10^n s} \left(\frac{1}{9} (10^{n+1} r - 10^{n+1}) + O(n) \right) - 1 - \frac{r-10}{9s} - \frac{r-s}{s} \\
&= \frac{10r}{9s} - \frac{10}{9s} + \frac{O(n)}{10^n s} - \frac{r-10}{9s} - 1 - \frac{r-s}{s} = \frac{O(n)}{10^n s}
\end{aligned}$$

Quindi il lemma è valido quando $m = 1$. Procediamo ora per induzione: consideriamo $m > 1$ e vogliamo approssimare la seguente quantità

$$\begin{aligned}
P_m(10^n s) &= \frac{1}{10^n s} \sum_{k=1}^{10^n s} P_{m-1}(k) \\
&= \frac{1}{10^n s} \left[\sum_{k=1}^{10^n} P_{m-1}(k) + \sum_{k=10^n}^{10^n s} P_{m-1}(k) \right] \\
&= \frac{1}{s} \left[\sum_{0 \leq j < n} \frac{1}{10^{n-j}} \sum_{10^j \leq k < 10^{j+1}} \frac{P_{m-1}(k)}{10^j} + \sum_{10^n \leq k \leq 10^n s} \frac{P_{m-1}(k)}{10^n} \right]
\end{aligned}$$

Possiamo affermare che la differenza

$$\left| \sum_{10^j \leq k \leq 10^{j+1}} \frac{P_{m-1}(k)}{10^j} - \sum_{10^j \leq k \leq 10^{j+1}} \frac{S_{m-1}\left(\frac{k}{10^j}\right)}{10^j} \right| \tag{3.14}$$

è minore di $q\epsilon$ se consideriamo $1 \leq q \leq 10$ e $j > N_{m-1}(\epsilon)$; infatti per induzione $|P_{m-1}(k) - S_{m-1}(\frac{k}{10^j})| < \epsilon$, e vale la disuguaglianza triangolare:

$$\begin{aligned} & \left| \sum_{10^j \leq k \leq 10^j q} \frac{P_{m-1}(k)}{10^j} - \sum_{10^j \leq k \leq 10^j q} \frac{S_{m-1}(\frac{k}{10^j})}{10^j} \right| \leq \\ & \sum_{10^j \leq k \leq 10^j q} \frac{|P_{m-1}(k) - S_{m-1}(\frac{k}{10^j})|}{10^j} \leq \\ & \frac{\epsilon \cdot (10^j q + 1 - 10^j)}{10^j} \leq q\epsilon. \end{aligned}$$

Inoltre è immediato notare che Q_{m-1} e R_{m-1} sono funzioni continue per il *Teorema fondamentale del calcolo integrale* (in particolare per quanto riguarda R_{m-1} , quanto detto vale perché quando $s = r$ essa si annulla). Quindi S_{m-1} è una funzione continua perché somma di funzioni continue e di conseguenza Riemann-integrabile, e per definizione di integrale possiamo dire che

$$\left| \sum_{10^j \leq k \leq 10^j q} \frac{S_{m-1}(\frac{k}{10^j})}{10^j} - \int_1^q S_{m-1}(t) dt \right| \quad (3.15)$$

è minore di $\epsilon \forall j > N$, dove N è un certo numero indipendente da q . Se consideriamo $N > N_{m-1}(\epsilon)$ vale che, $\forall n > N$, la differenza

$$|P_m(10^n s) - \frac{1}{s} \left(\sum_{0 \leq j < n} \frac{1}{10^{n-j}} \int_1^{10} S_{m-1}(t) dt + \int_1^s S_{m-1}(t) dt \right)| \quad (3.16)$$

è limitata da $\sum_{j=0}^N (\frac{M}{10^{n-j}}) + \sum_{N < j < n} \frac{11\epsilon}{10^{n-j}} + 11\epsilon$, dove M è l'estremo superiore della somma di (3.14) e (3.15) per tutti i $j \in \mathbb{N}$. Infatti se applichiamo (3.14) e (3.15) e notiamo che $q \leq 10$ otteniamo:

$$\begin{aligned} & \frac{1}{10^n s} \sum_{k=1}^{10^n s} P_{m-1}(k) - \frac{1}{s} \left(\sum_{0 \leq j < n} \frac{1}{10^{n-j}} \sum_{10^j \leq k < 10^{j+1}} \frac{S_{m-1}(\frac{k}{10^j}) + \epsilon}{10^j} + \sum_{10^j \leq k < 10^j s} \frac{S_{m-1}(\frac{k}{10^j}) + \epsilon}{10^j} \right) = \\ & \frac{1}{s} \left[\sum_{0 \leq j < N} \sum_{10^j \leq k < 10^{j+1}} \frac{\frac{P_{m-1}(k)}{10^j} - \frac{S_{m-1}(\frac{k}{10^j})}{10^j}}{10^{n-j}} + \sum_{N \leq j < n} \sum_{10^j \leq k < 10^{j+1}} \frac{\frac{P_{m-1}(k)}{10^j} - \frac{S_{m-1}(\frac{k}{10^j})}{10^j} + \epsilon}{10^{n-j}} + \right. \\ & \left. \sum_{10^n \leq k < 10^n s} \frac{\frac{P_{m-1}(k)}{10^j} - \frac{S_{m-1}(\frac{k}{10^j})}{10^j} + \epsilon}{10^j} \right] \leq \\ & \sum_{0 \leq j < N} \frac{M}{10^{n-j}} + \sum_{N \leq j < n} \frac{q\epsilon + \epsilon}{10^{n-j}} + q\epsilon + \epsilon \leq \\ & \sum_{0 \leq j < N} \frac{M}{10^{n-j}} + \sum_{N \leq j < n} \frac{11\epsilon}{10^{n-j}} + 11\epsilon \end{aligned}$$

Il primo termine compare perché le stime (3.14) e (3.15) valgono solo per $n > N$. Infine, la somma $\sum_{0 \leq j < n} \frac{1}{10^{n-j}}$ che appare in (3.16) è uguale a $\frac{1-10^{-n}}{9}$ per quanto detto in (3.9), quindi possiamo concludere che

$$|P_m(10^n s) - \frac{1}{s} \left(\frac{1}{9} \int_1^{10} S_{m-1}(t) dt + \int_1^s S_{m-1}(t) dt \right)|$$

può essere resa più piccola di, ad esempio, 20ϵ , a patto di prendere n abbastanza grande. Questo conclude la dimostrazione: riconsiderando (3.11) e (3.12) possiamo concludere che:

$$\begin{aligned}
 & |P_m(10^n s) - Q_m(s) - R_m(s)| \\
 = & |P_m(10^n s) - \frac{1}{s}(\frac{1}{9} \int_1^{10} Q_{m-1}(t) dt + \int_1^s Q_{m-1}(t) dt + \frac{1}{9} \int_r^{10} R_{m-1}(t) dt) - \frac{1}{s} \int_r^s R_{m-1}(t) dt| \\
 \leq & |P_m(10^n s) - \frac{1}{s}(\frac{1}{9} \int_1^{10} (Q_{m-1}(t) + R_{m-1}(t)) dt + \int_1^s (Q_{m-1}(t) + R_{m-1}(t)) dt)| \\
 = & |P_m(10^n s) - \frac{1}{s}(\frac{1}{9} \int_1^{10} S_{m-1}(t) dt + \int_1^s S_{m-1}(t) dt)| \leq 20\epsilon.
 \end{aligned}$$

□

Dimostriamo ora il seguente Teorema, che ci permetterà di approssimare $P_m(x)$ con $\log_{10} r$.

Teorema 3.2.2. *Definiamo*

$$S_m(t) = Q_m(t) + R_m(t)$$

allora, per ogni $\epsilon > 0$, esiste un numero $N(\epsilon)$ tale che

$$|S_m(s) - \log_{10} r| < \epsilon$$

per ogni $s \in [1, 10]$ e per ogni $m > N(\epsilon)$. In altri termini, $\lim_{m \rightarrow \infty} S_m(s) = \log_{10} r$ uniformemente se $s \in [1, 10]$.

Dimostrazione. Grazie al lemma 3.2.1, per provare questo risultato basta mostrare che $\exists M(\epsilon)$ tale che, considerando $1 \leq s \leq 10$, $\forall m > M$, valgono le seguenti stime:

$$|Q_m(s) - \log_{10} r| < \epsilon \quad e \quad |R_m(s)| < \epsilon$$

Iniziamo analizzando R_m : esso è definito in (3.12), e svolgendo i calcoli troviamo che

$$\begin{aligned}
 R_0(s) &= -1; \\
 R_1(s) &= \frac{r-s}{s} = -1 + \frac{r}{s}; \\
 R_2(s) &= \frac{1}{s} \int_r^s R_1(t) dt = \frac{1}{s} \int_r^s (-1 + \frac{r}{t}) dt = \frac{r-s}{s} \frac{r}{s} \ln \frac{s}{r} = -1 + \frac{r}{s} (1 + \ln \frac{s}{r}); \\
 &\dots \\
 R_m(s) &= -1 + \frac{r}{s} (1 + \frac{1}{1!} \ln \frac{s}{r} + \dots + \frac{1}{(m-1)!} (\ln \frac{s}{r})^{m-1});
 \end{aligned}$$

Ricordiamo ora che

$$e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!}$$

Quindi R_m converge uniformemente a $-1 + \frac{r}{s} \exp(\ln \frac{s}{r}) = -1 + 1 = 0$, ed è dunque minore di ϵ definitivamente. Per quanto riguarda Q_m , la definizione (3.12) può essere riscritta nel seguente modo:

$$Q_m(s) = \frac{1}{s} (c_m + 1 + \int_1^s Q_{m-1}(t) dt)$$

dove

$$c_m = \frac{1}{9} \left(\int_1^{10} Q_{m-1}(t) dt + \int_r^{10} R_{m-1}(t) dt \right) - 1$$

e svolgendo i calcoli troviamo che:

$$\begin{aligned} Q_1(s) &= \frac{1}{s} (c_1 + 1 + \int_1^s 1 dt) = \frac{1}{s} (c_1 + 1 + s - 1) = 1 + \frac{c_1}{s} \\ Q_2(s) &= \frac{1}{s} (c_2 + 1 + \int_1^s (1 + \frac{c_1}{s}) dt) = 1 + \frac{1}{s} (c_2 + c_1 \ln s) \\ &\dots \\ Q_m(s) &= 1 + \frac{1}{s} (c_m + \frac{1}{1!} c_{m-1} \ln s + \dots + \frac{1}{(m-1)!} c_1 (\ln s)^{m-1}) \end{aligned} \quad (3.17)$$

dove le costanti $c_1, c_2, \dots$ sono date da

$$\begin{aligned} c_1 &= \frac{1}{9} \left(\int_1^{10} Q_0 dt + \int_r^{10} R_0 dt \right) - 1 = \frac{1}{9} \left(\int_1^{10} 1 dt - \int_r^{10} 1 dt \right) - 1 = \frac{1}{9} 9 - \frac{1}{9} (10 - r) - 1 = \frac{r - 10}{9} \\ c_2 &= \frac{1}{9} \left(\int_1^{10} Q_1 dt + \int_r^{10} R_1 dt \right) - 1 = \frac{1}{9} \left(\int_1^{10} (1 + \frac{r-10}{9t}) dt - \int_r^{10} (1 - \frac{r}{t}) dt \right) - 1 \\ &= \frac{1}{9} \frac{r-10}{9} \ln 10 + r - 10 + r \ln \frac{10}{r} = \frac{1}{9} (c_1 \ln 10 + r(1 + \ln \frac{10}{r}) - 10) \\ &\dots \\ c_{m+1} &= \frac{1}{9} (c_m \ln 10 + \frac{1}{2!} c_{m-1} (\ln 10)^2 + \dots + \frac{1}{m!} c_1 (\ln 10)^m + r(1 + \frac{1}{1!} \ln \frac{10}{r} + \dots + \frac{1}{m!} (\ln \frac{10}{r})^m) - 10) \end{aligned} \quad (3.18)$$

c_{m+1} ha una scrittura molto complicata, ma può essere riformulato nel seguente modo:

$$\begin{aligned} c_{m+1} &= \frac{1}{10} c_{m+1} + \frac{9}{10} c_{m+1} \\ &= \frac{1}{10} c_{m+1} + \frac{9}{10} \frac{1}{9} (c_m \ln 10 + \frac{1}{2!} c_{m-1} (\ln 10)^2 + \dots + \frac{1}{m!} c_1 (\ln 10)^m + \\ &\quad r(1 + \frac{1}{1!} \ln \frac{10}{r} + \dots + \frac{1}{m!} (\ln \frac{10}{r})^m) - 10) \\ &= \frac{1}{10} (c_{m+1} + c_m \ln 10 + \frac{1}{2!} c_{m-1} (\ln 10)^2 + \dots + \frac{1}{m!} c_1 (\ln 10)^m) \\ &\quad + \frac{r}{10} (1 + \frac{1}{1!} \ln \frac{10}{r} + \dots + \frac{1}{m!} (\ln \frac{10}{r})^m) - 1 \end{aligned} \quad (3.19)$$

Per studiare questa serie usiamo la funzione generatrice

$$C(z) = c_1 z + c_2 z^2 + \dots;$$

Dove con *funzione generatrice* intendiamo una serie formale di potenze i cui coefficienti sono i componenti di una successione indicizzata dai numeri naturali. Ricordando che $10^z = 1 + z \ln 10 + \frac{1}{2!} (z \ln 10)^2 + \dots$ possiamo concludere che c_{m+1} coincide con il coefficiente relativo a z^{m+1} nella funzione

$$\frac{1}{10} C(z) 10^z + \frac{r}{10} \left(\frac{10}{r} \right)^z \left(\frac{z}{1-z} \right) - \frac{z}{1-z} \quad (3.20)$$

Infatti

$$\begin{aligned} C(z)10^z &= (c_1z + c_2z^2 + \dots)(1 + z \ln 10 + \frac{1}{2!}(z \ln 10)^2 + \dots) \\ &= \sum_{m=0}^{\infty} (c_{m+1} + c_m \ln 10 + \frac{c_{m-1}}{2!}(\ln 10)^2 + \dots + \frac{c_1}{m!}(\ln 10)^m) z^{m+1} \end{aligned}$$

e

$$\begin{aligned} \frac{r}{10} \left(\frac{10}{r}\right)^z \left(\frac{z}{1-z}\right) - \frac{z}{1-z} &= \frac{r}{10} \left(1 + z \ln \left(\frac{10}{r}\right) + \frac{1}{2!} \left(z \ln \left(\frac{10}{r}\right)\right)^2 + \dots\right) \sum_{m=0}^{\infty} z^{m+1} - \sum_{m=0}^{\infty} z^{m+1} \\ &= \sum_{m=0}^{\infty} \left[\frac{r}{10} \left(1 + \ln \left(\frac{10}{r}\right) + \dots + \frac{1}{m!} \ln \left(\frac{10}{r}\right)^m\right) \right] z^{m+1} \end{aligned}$$

Questa condizione vale $\forall m$, quindi la (3.20) corrisponde a $C(z)$ e otteniamo la seguente formula esplicita

$$C(z) = \frac{-z}{1-z} \left(\frac{\frac{10}{r} z^{-1} - 1}{\frac{10}{r} z^{-1} - 1} \right)$$

Vogliamo capire come si comporta $C(z)$ asintoticamente. Ricordando che $\lim_{x \rightarrow 0} \frac{a^x - 1}{x} = \ln a$ possiamo affermare che

$$\lim_{z \rightarrow 1} \frac{\frac{10}{r} z^{-1} - 1}{\frac{10}{r} z^{-1} - 1} = \frac{\ln \frac{10}{r}}{\ln 10} = 1 - \log_{10} r$$

Definiamo la funzione analitica $R(z)$, dipendente dalla variabile complessa z , come segue:

$$R(z) = C(z) + \frac{1 - \log_{10} r}{1 - z}$$

$\forall z \in \mathbb{C}$, $|z| < |1 + \frac{2\pi i}{\ln 10}|$. Per quanto detto prima, $R(z)$ converge per $z = 1$, quindi i suoi coefficienti tendono a zero, e questo comporta che i coefficienti di $C(z)$ devono comportarsi come quelli di $\frac{\log_{10} r - 1}{1 - z} = \sum_{m=0}^{\infty} (\log_{10} r - 1) z^m$, e dunque $\lim_{m \rightarrow \infty} c_m = \log_{10} r - 1$. Combinando questo risultato con (3.17) possiamo infine concludere che:

$$\lim_{m \rightarrow \infty} Q_m(s) = 1 + \frac{\log_{10} r - 1}{s} \left(1 + \ln s + \frac{1}{2!} (\ln s)^2 + \dots\right) = 1 + \frac{\log_{10} r - 1}{s} \exp(\ln s) = \log_{10} r.$$

□

Dal primo lemma (3.2.1) possiamo dedurre che $p(r) = \lim_{n \rightarrow \infty} P_m(10^n s) = S_m(s)$. Considerando che $S_m(s)$ non è costante, anche in questo caso il limite $\lim_{n \rightarrow \infty} P_m(n)$ non è ben definito $\forall m$ fissato. Notiamo tuttavia che, in virtù del Teorema (3.2.2) possiamo affermare che la successione di funzioni S_m converge uniformemente a $\log_{10} r$. Questo ci porta a concludere che $p(r)$ può essere approssimata con $\log_{10} r$. Siamo così giunti alla Legge di Benford attraverso un calcolo diretto; l'andamento logaritmico non è mai raggiunto con precisione ma rimane un'approssimazione della vera distribuzione.

Capitolo 4

Catene di Markov e invarianza di scala

Questa sezione è tratta dall'articolo "*The Newcomb-Benford law: Scale invariance and a simple Markov process based on it*" [5]. In primo luogo generalizzeremo la formula per la distribuzione di Benford (1.2) ad una formula per la probabilità delle prime m cifre, per poi costruire una Catena di Markov con spazio degli stati $\{1, 2, 3, 4, 5, 6, 7, 8, 9\}$ basandoci sull'invarianza di scala di dataset che seguono la legge di Benford. In ultima analisi calcoleremo la misura invariante per la catena di Markov trovata e noteremo che coincide proprio con la legge di Benford, deducendo grazie al lemma 2.1.3 sul comportamento asintotico di una Catena di Markov che, per tempi molto grandi, le prime cifre significative tendono a distribuirsi secondo tale legge.

4.1 Distribuzione delle prime m cifre

In questa sezione ci occuperemo di generalizzare (1.2), ottenendo una formula che esprima la probabilità che le prime m cifre significative valgano rispettivamente $(d_1, d_2, \dots, d_m)$, con $d_1 \in \{1, \dots, 9\}$ e $d_i \in \{0, 1, \dots, 9\}$ se $i \geq 2$. Tale probabilità vale

$$p_{d_1, d_2, \dots, d_m} = \log_{10} [1 + (\sum_{i=1}^m d_i \cdot 10^{m-i})^{-1}] \quad (4.1)$$

Ricaveremo successivamente, a partire da questa formula, la probabilità che la m -esima cifra significativa valga d_m , indipendentemente dal valore delle $m - 1$ cifre precedenti.

Innanzitutto ricaviamo, con un argomento alternativo a quello mostrato nel capitolo precedente, la densità della legge di Benford continua, ovvero la densità relativa alla distribuzione della prima cifra significativa, che indichiamo con $f(x)$. In questo caso supponiamo che la distribuzione della prima cifra sia invariante sotto un cambio di scala, ovvero $f(\lambda x) = g(\lambda)f(x)$, per una opportuna funzione $g(\lambda)$. La prima cifra significativa assume valori in $[1, 10)$, quindi

$$\int_1^{10} f(x) dx = 1 \quad (4.2)$$

che implica

$$\begin{aligned} 1 &= \int_{\lambda}^{10\lambda} f(\lambda x) d(\lambda x) = \int_{\lambda}^{10\lambda} g(\lambda) f(x) d(\lambda x) = \int_1^{10} \lambda g(\lambda) f(x) d(x) \\ &\Rightarrow g(\lambda) = \lambda^{-1} \Rightarrow f(\lambda x) = \lambda^{-1} f(x) \end{aligned}$$

Derivando entrambi i membri dell'uguaglianza ottenuta e ponendo $\lambda = 1$ otteniamo che $xf'(x) = -f(x)$. Ricordiamo il *Teorema sulle funzioni omogenee di Eulero*:

Teorema 4.1.1. (*Teorema sulle Funzioni Omogenee di Eulero*) Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$ una funzione differenziabile, allora essa è omogenea di grado k se e solo se vale la seguente relazione:

$$\sum_{i=1}^n \frac{\partial f}{\partial x_i}(x_1, \dots, x_n) x_i = kf(x_1, \dots, x_n)$$

Nel nostro caso questo teorema implica che $f(x)$ è una funzione omogenea di grado -1 , e dalla condizione (4.2) otteniamo la densità:

$$f(x) = \frac{x^{-1}}{\ln 10}, \quad 0 \leq x < 10$$

Passiamo ora alla dimostrazione di (4.1). Notiamo che la probabilità che la prima cifra significativa valga d è $\int_d^{d+1} f(x) dx$. Generalizziamo questo concetto alle prime m cifre significative; considerando la stringa $(d_1, \dots, d_m)$, è facile notare che i numeri le cui prime m cifre significative corrispondono esattamente a tale sequenza sono quelli compresi tra $d_1 + d_2 10^{-1} + \dots + d_m 10^{-(m-1)}$ e $d_1 + d_2 10^{-1} + \dots + (d_m + 1) 10^{-(m-1)}$, quindi

$$p_{d_1, d_2, \dots, d_m} = \int_{\sum_{i=1}^m d_i \cdot 10^{-(i-1)}}^{10^{-(m-1)} + \sum_{i=1}^m d_i \cdot 10^{-(i-1)}} f(x) dx$$

Possiamo così concludere la (4.1):

$$\begin{aligned} p_{d_1, \dots, d_m} &= \frac{1}{\log 10} \int_{\sum_{i=1}^m d_i \cdot 10^{-(i-1)}}^{10^{-(m-1)} + \sum_{i=1}^m d_i \cdot 10^{-(i-1)}} \frac{1}{x} dx \\ &= \frac{1}{\log 10} [\log(10^{-(m-1)} + \sum_{i=1}^m d_i \cdot 10^{-(i-1)}) - \log(\sum_{i=1}^m d_i \cdot 10^{-(i-1)})] \\ &= \frac{1}{\log 10} [\log(1 + \frac{10^{-(m-1)}}{\sum_{i=1}^m d_i \cdot 10^{-(i-1)}})] \\ &= \frac{1}{\log 10} [\log(1 + \frac{1}{\sum_{i=1}^m d_i \cdot 10^{m-i}})] \end{aligned}$$

Grazie alla (4.1) possiamo infine calcolare la probabilità $p_d^{(m)}$ che la m -esima cifra valga d : basta infatti sommare per tutti i possibili valori delle $m-1$ cifre precedenti:

$$p_d^{(m)} = \sum_{d_1=1}^9 \sum_{d_2=0}^9 \dots \sum_{d_{m-1}=0}^9 p_{d_1, d_2, \dots, d_{m-1}, d}$$

4.2 Costruzione della catena di Markov

In questa sezione costruiremo una catena di Markov (definita in 2.1, pagina 3), supponendo vera la legge di Benford e l'invarianza di scala. I valori 1, 2, 3, 4, 5, 6, 7, 8, 9, che fino ad adesso indicavano i possibili valori assunti dalla prima cifra significativa, perderanno questo significato e verranno invece considerati come lo spazio degli stati della catena.

Consideriamo un insieme di dati $\{r_n(0)\}$; se esso rispetta la legge di Benford, allora grazie all'invarianza di scala anche $\{\lambda r_n(0)\}$ la rispetterà. Generiamo quindi dei dataset nel seguente modo: $\{r_n(t) = \lambda^t r_n(0)\}$ con $t \in \mathbb{N}$. Ipotizzando $\lambda=2$ possiamo considerare la trasformazione $\{r_n(t)\} \rightarrow \{r_n(t+1) = 2r_n(t)\}$. Ci chiediamo quindi in che modo cambiano le prime cifre significative di un dataset quando tutti i suoi record vengono moltiplicati per due, come illustrato in figura 4.1. I record che hanno come prima cifra significativa $d = 5, 6, 7, 8, 9$ a seguito della trasformazione inizieranno per 1, mentre se consideriamo i record che hanno come prima cifra significativa $d = 1, 2, 3, 4$ il calcolo diventa più complicato, infatti il valore assunto dopo la trasformazione dipende anche dalla seconda cifra significativa. In particolare, i valori che hanno come prime due cifre $(d, 0)$, $(d, 1)$, $(d, 2)$, $(d, 3)$, $(d, 4)$ una volta raddoppiati inizieranno con $2d$, mentre gli altri inizieranno con $2d + 1$. Definiamo α_d come la probabilità che i record che inizialmente avevano come prima cifra $d = 1, 2, 3, 4$, una volta raddoppiati, abbiano come prima cifra significativa $2d$. Dunque

$$\alpha_d = \frac{\sum_{d_2=0}^4 p_{d,d_2}}{p_d}$$

Questo valore può essere calcolato esplicitamente se supponiamo valida la legge di Benford:

$$\begin{aligned} \alpha_1 &= \frac{\log_{10} \frac{3}{2}}{\log_{10} 2} \sim 0.58496 \\ \alpha_2 &= \frac{\log_{10} \frac{5}{4}}{\log_{10} \frac{3}{2}} \sim 0.55034 \\ \alpha_3 &= \frac{\log_{10} \frac{7}{6}}{\log_{10} \frac{4}{3}} \sim 0.53584 \\ \alpha_4 &= \frac{\log_{10} \frac{9}{8}}{\log_{10} \frac{5}{4}} \sim 0.52784 \end{aligned} \tag{4.3}$$

Mostriamo esplicitamente il calcolo di α_1 :

$$\alpha_1 = \frac{p_{1,0} + p_{1,1} + p_{1,2} + p_{1,3} + p_{1,4}}{p_1} \tag{4.4}$$




Figura 4.1: Diagramma che mostra come cambia la prima cifra significativa quando tutti i record di un dataset vengono duplicati

Calcoliamo i valori delle probabilità:

$$\begin{aligned}
 p_{1,0} &= \log_{10} \left[1 + \frac{1}{1 \cdot 10 + 0 \cdot 1} \right] = \log_{10} \left(\frac{11}{10} \right) \\
 p_{1,1} &= \log_{10} \left[1 + \frac{1}{1 \cdot 10 + 1 \cdot 1} \right] = \log_{10} \left(\frac{12}{11} \right) \\
 p_{1,2} &= \log_{10} \left[1 + \frac{1}{1 \cdot 10 + 2 \cdot 1} \right] = \log_{10} \left(\frac{13}{12} \right) \\
 p_{1,3} &= \log_{10} \left[1 + \frac{1}{1 \cdot 10 + 3 \cdot 1} \right] = \log_{10} \left(\frac{14}{13} \right) \\
 p_{1,4} &= \log_{10} \left[1 + \frac{1}{1 \cdot 10 + 4 \cdot 1} \right] = \log_{10} \left(\frac{15}{14} \right) \\
 p_1 &= \log_{10} \left[1 + \frac{1}{1} \right] = \log_{10} 2
 \end{aligned}$$

e li sostituiamo in (4.4)

$$\alpha_1 = \frac{\log_{10} \left(\frac{11}{10} \right) + \log_{10} \left(\frac{12}{11} \right) + \log_{10} \left(\frac{13}{12} \right) + \log_{10} \left(\frac{14}{13} \right) + \log_{10} \left(\frac{15}{14} \right)}{\log_{10} 2} = \frac{\log_{10} \left(\frac{15}{10} \right)}{\log_{10} 2} = \frac{\log_{10} \left(\frac{3}{2} \right)}{\log_{10} 2}$$

Per $\alpha_2, \alpha_3, \alpha_4$ il calcolo è analogo. Quindi, se indichiamo con $\{p_d(t)\}$ la distribuzione delle prime cifre significative di $\{r_n(t)\}$, otteniamo che:

$$\begin{aligned}
 p_1(t+1) &= p_5(t) + p_6(t) + p_7(t) + p_8(t) + p_9(t) \\
 p_2(t+1) &= \alpha_1 p_1(t) \\
 p_3(t+1) &= (1 - \alpha_1) p_1(t) \\
 p_4(t+1) &= \alpha_2 p_2(t) \\
 p_5(t+1) &= (1 - \alpha_2) p_2(t) \\
 p_6(t+1) &= \alpha_3 p_3(t) \\
 p_7(t+1) &= (1 - \alpha_3) p_3(t) \\
 p_8(t+1) &= \alpha_4 p_4(t) \\
 p_9(t+1) &= (1 - \alpha_4) p_4(t)
 \end{aligned} \tag{4.5}$$

In generale α_d dipende dalla distribuzione della prima o delle prime due cifre significative ma, se supponiamo valida la legge di Benford, esse hanno un valore costante (calcolato in (4.3)). Possiamo così esprimere $\mathbf{p}(t+1)$ in forma matriciale:

$$\mathbf{p}(t+1)^T = \mathbf{p}(t)^T \cdot Q \quad (4.6)$$

dove $\mathbf{p}(t) = (p_1(t), \dots, p_9(t))^T$ è un vettore colonna e

$$Q = \begin{bmatrix} 0 & \alpha_1 & 1 - \alpha_1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & \alpha_2 & 1 - \alpha_2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & \alpha_3 & 1 - \alpha_3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & \alpha_4 & 1 - \alpha_4 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

è una matrice fissata, non dipendente da t o dalla distribuzione delle cifre. L'equazione (4.6) descrive, in questo caso, una catena di Markov con matrice di transizione Q e spazio degli stati $E = \{1, 2, \dots, 9\}$.

4.3 Probabilità invarianti per la Catena di Markov

In questa sezione ci occupiamo di cercare la probabilità invariante per la catena di Markov costruita nel paragrafo precedente. $X \sim \text{Markov}(Q)$ è irriducibile perché tutti i suoi stati comunicano ed è definita su uno spazio degli stati finito $E = \{1, 2, 3, 4, 5, 6, 7, 8, 9\}$. Esiste dunque un'unica probabilità invariante, che indichiamo con λ . Inoltre la catena è aperiodica: se, per esempio, consideriamo il periodo di 1, abbiamo $1 \rightarrow 2 \rightarrow 4 \rightarrow 8 \rightarrow 1$ oppure $1 \rightarrow 3 \rightarrow 7 \rightarrow 1$, e $MCD(4, 3) = 1$. Quindi per il lemma (2.1.2) il periodo della catena è 1 e vale il lemma sul Comportamento Asintotico (2.1.3). Definiamo $\lambda(y)$ la probabilità di salto in y , per ogni $y \in \{1, \dots, 9\}$; notiamo innanzitutto che vale la condizione di normalizzazione $\sum_{y=1}^9 \lambda(y) = 1$ e, come ricordato in (2.1.4), una probabilità è invariante se soddisfa $\lambda(y) = \sum_{x \in E} \lambda(x)q(x, y)$. Basta quindi risolvere il sistema

$$\begin{cases} \sum_{y=1}^9 \lambda(y) = 1 \\ \lambda(y) = \sum_{x \in E} \lambda(x)q(x, y) \end{cases} \quad (4.7)$$

che, scritto esplicitamente e tenendo conto delle probabilità di salto, diventa:

$$\left\{ \begin{array}{l} \sum_{y=1}^9 \lambda(y) = 1 \\ \lambda(1) = \lambda(5) + \lambda(6) + \lambda(7) + \lambda(8) + \lambda(9) \\ \lambda(2) = \alpha_1 \lambda(1) \\ \lambda(3) = (1 - \alpha_1) \lambda(1) \\ \lambda(4) = \alpha_2 \lambda(2) \\ \lambda(5) = (1 - \alpha_2) \lambda(2) \\ \lambda(6) = \alpha_3 \lambda(3) \\ \lambda(7) = (1 - \alpha_3) \lambda(3) \\ \lambda(8) = \alpha_4 \lambda(4) \\ \lambda(9) = (1 - \alpha_4) \lambda(4) \end{array} \right. \quad (4.8)$$

La soluzione è facilmente ricavabile tramite sostituzione, ottenendo la probabilità invariante:

$$\lambda = \begin{bmatrix} \frac{1}{3+\alpha_1\alpha_2} \\ \frac{\alpha_1}{3+\alpha_1\alpha_2} \\ \frac{1-\alpha_1}{3+\alpha_1\alpha_2} \\ \frac{\alpha_1\alpha_2}{3+\alpha_1\alpha_2} \\ \frac{(1-\alpha_2)\alpha_1}{3+\alpha_1\alpha_2} \\ \frac{\alpha_3(1-\alpha_1)}{3+\alpha_1\alpha_2} \\ \frac{(1-\alpha_3)(1-\alpha_1)}{3+\alpha_1\alpha_2} \\ \frac{\alpha_1\alpha_2\alpha_4}{3+\alpha_1\alpha_2} \\ \frac{\alpha_1\alpha_2(1-\alpha_4)}{3+\alpha_1\alpha_2} \end{bmatrix} = \begin{bmatrix} 0,301 \\ 0,176 \\ 0,125 \\ 0,097 \\ 0,079 \\ 0,067 \\ 0,058 \\ 0,051 \\ 0,046 \end{bmatrix}.$$

se scegliamo gli α_d come in (4.3). Notiamo che in questo caso λ corrisponde alle probabilità stimate dalla legge di Benford. Possiamo quindi concludere che, se la distribuzione iniziale è quella di Benford, allora essa verrà preservata ad ogni tempo dalla catena, come ci aspettavamo dall'invarianza. Se invece la distribuzione iniziale è diversa da quella di Benford, grazie a (2.1.3) possiamo comunque concludere che, sotto le ipotesi fatte, la catena tenderà a tale distribuzione al tendere di t ad infinito.

Capitolo 5

Applicazioni della legge di Benford

5.1 Social Network

La legge di Benford è un utile strumento usato per identificare comportamenti inaspettati in moltissimi settori, per esempio è ampiamente usata per analizzare le discrepanze in ambito economico e finanziario, per analizzare i dati delle elezioni ed addirittura per capire quante volte le immagini JPEG sono state compresse.

In questo capitolo analizziamo la correlazione della legge di Benford con i Social Network, chiedendoci se si applica alle relazioni tra gli utenti di questi ultimi e se può essere utile per analizzarne i comportamenti. Sappiamo già che la distribuzione non ha valenza universale, quindi ci aspettiamo dei casi in cui essa non verrà rispettata. Questo può succedere per i motivi più disparati, il nostro scopo sarà quello di comprendere questi motivi e capire se possiamo usare questa non aderenza per individuare eventuali comportamenti sospetti.

Quanto detto è stato tratto dall'articolo *Benford's Law Applies to Online Social Network*[4].

5.1.1 Introduzione

Prendiamo in esame cinque dei Social Network più usati nel 2015, anno di pubblicazione dell'articolo: Facebook, Twitter, Google Plus, Pinterest e Livejournal. Inizialmente analizzeremo i Social Network nel loro complesso, concentrandoci sulle prime cifre significative del numero di amici e seguaci e su quelle del numero di post dei loro utenti, per poi considerare i singoli utenti e la rete di amicizie che ognuno di loro ha creato. In entrambi i casi studiamo l'aderenza alla legge di Benford e ci chiediamo se, ogniqualvolta questa non viene rispettata, possiamo concludere che si stanno verificando delle frodi o dei comportamenti sospetti. Per fare ciò utilizzeremo due strumenti: l'*indice di correlazione di Pearson* (paragrafo 2.2, pagina 4) e il *test di Kolmogorov-Smirnov* (paragrafo 2.3, pagina 5). Più precisamente, calcoleremo l'indice di correlazione tra la distribuzione delle prime cifre significative trovata sperimentalmente e quella predetta da Benford ed eseguiremo il test di Kolmogorov-Smirnov ponendo come $F(x)$ la funzione di ripartizione della distribuzione delle prime cifre significative rilevata

e come $F_0(x)$ la distribuzione della *legge di Benford continua*, esplicitata in (3.3) a pagina 9. Se analizziamo gli esempi dati da Benford, notiamo che molte delle successioni che aderiscono alla legge hanno un andamento esponenziale; questo tipo di andamento è molto frequente nei Social Network, quindi possiamo aspettarci che la Legge di Benford si applicherà a queste strutture.

5.1.2 Raccolta dei Dati / Campionamento

Facebook

L'autrice, Jennifer Golbeck, seleziona gli utenti mediante il loro ID-utente. Per effettuare un campionamento il più uniforme possibile viene considerato inizialmente l'utente con ID=1 e vengono raccolti i suoi dati; successivamente l'ID viene aumentato di 10'000 e vengono raccolti i dati relativi al nuovo ID, fino ad esaurire gli utenti. Se per un certo ID non troviamo alcun dato consideriamo l'utente successivo, incrementando l'ID di 1, fino a che non troviamo un account che possiamo utilizzare, per poi proseguire con il campionamento come descritto precedentemente. Per ogni utente raccogliamo il numero di amici.

Twitter

Il metodo di selezione degli utenti è analogo a quello usato per Facebook, ma l'ID viene incrementato di 50'000. Raccogliamo il numero di amici, seguaci e tweet (richiediamo che gli utenti selezionati abbiano almeno un elemento in ognuna di queste tre classi). Tra gli utenti così selezionati consideriamo poi quelli con più di 100 amici e raccogliamo anche il numero di amici, seguaci e tweet dei loro amici.

Google Plus

Usiamo un dataset preso dallo *Stanford Network Analysis Project* (SNAP) e raccogliamo il numero di amici di ogni utente e il numero di amici dei loro amici.

Pinterest

Usiamo un dataset preso dal *Social Curation Dataset* e raccogliamo il numero di seguaci, seguiti e pin di utenti che ne hanno almeno uno di ognuno.

LiveJournal

Anche in questo caso usiamo un dataset preso dallo *Stanford Network Analysis Project* (SNAP) e raccogliamo il numero di amici di ogni utente e il numero di amici dei loro amici.

5.1.3 Risultati

Analizzando i dati degli utenti selezionati come sopra descritto (il numero di utenti analizzati per ogni Social è specificato in tabella 5.1), possiamo concludere che la distribuzione delle prime cifre significative è esattamente quella che ci aspettiamo in ogni piattaforma tranne che in un caso specifico: il numero dei seguiti su Pinterest. Consideriamo in un primo momento

il numero di amici su Facebook, Google Plus e LiveJournal, di amici e seguaci su Twitter e di seguaci su Pinterest. Come mostrato nella tabella 5.1 l'indice di correlazione di Pearson è superiore a 0.96 e il p-value relativo al test di Kolmogorov-Smirnov è maggiore di 0.97. Ricordiamo che il p-value è il più basso livello di significatività per cui i dati osservati portano a rifiutare H_0 . Un p-value alto implica quindi una forte indicazione che H_0 sia vera, che in questo caso significa che la distribuzione delle prime cifre significative dei Social Network coincide con la legge di Benford.

La figura 5.1 mostra la distribuzione delle prime cifre significative dei vari Social Network. Notiamo che, come già potevamo intuire dalle statistiche precedentemente analizzate, il loro andamento coincide con l'andamento logaritmico predetto da Benford, con una predominanza delle cifre basse rispetto a quelle alte. Osservazioni analoghe possono essere compiute se analizziamo il numero di tweets e pin: in questo caso gli indici di correlazione valgono rispettivamente 0.9998 e 0.9960.

L'unica eccezione trovata a questa legge compare quando analizziamo il numero di seguiti di Pinterest: come mostrato in figura 5.2, nella distribuzione delle prime cifre significative può essere osservata una predominanza della cifra 5, che compare un numero inaspettatamente alto di volte. Questo picco non è previsto dalla legge di Benford; come possiamo spiegarlo? È necessario indagare più a fondo, quindi procediamo all'analisi del funzionamento di Pinterest. Notiamo che, al momento dell'iscrizione, agli utenti è chiesto di selezionare *almeno 5* interessi da seguire, ed è proprio questa forzatura che causa il picco. Anche se in ogni momento ogni utente può cambiare i propri interessi selezionandone un numero arbitrario, quasi nessuno di essi lo fa, e questo spiega la predominanza di 5 nel numero totale di seguiti. Questa osservazione mostra una caratteristica intrinseca della legge: essa può perdere di validità se i comportamenti dei soggetti presi in analisi sono influenzati da una forza esterna. In questo caso la forza esterna è Pinterest stesso, ma ci sono infinite possibilità.

Possiamo analizzare, al posto delle prime cifre, le seconde. La Legge di Benford è ancora valida, ma la distribuzione è più uniforme e comprende anche lo 0:

k	0	1	2	3	4	5	6	7	8	9
p _Z (k)	0.1197	0.1139	0.1088	0.1043	0.1003	0.0967	0.0934	0.0904	0.0876	0.0850

I casi da noi analizzati rispettano anche questa distribuzione: per ogni Network l'indice di correlazione è superiore a 0.97, mentre il p-value del test di Kolmogorov-Smirnov è superiore a 0.98 per gli amici di Twitter, Facebook, Pinterest e Google Plus, mentre vale 0.76 per i seguaci su Twitter e 0.79 per i seguaci su LiveJournal. L'analisi della distribuzione delle seconde cifre elimina anche il picco in 5 dei seguiti su Pinterest, che in questo caso si comportano come previsto.

Fino a questo punto abbiamo analizzato i Social Network nel loro complesso. Ci concentriamo ora sui singoli utenti e sulla rete di amici che ognuno di essi crea all'interno dei Social. A questo scopo consideriamo utenti di Twitter, Google Plus e LiveJournal con almeno 100 amici, e studiamo la rete di amicizie che hanno costruito. Ci interessa, in particolare, la distribuzione delle prime cifre significative del numero di amici-di-amici di ognuno di loro. In Google Plus, il 91.5% degli utenti analizzati ha un indice di correlazione maggiore di 0.9, mentre in LiveJournal questo vale per l'85.1% di loro. Per quanti riguarda Twitter, l'89.7% degli utenti ha un




Figura 5.1: Distribuzione delle prime cifre significative di amici su Facebook, Google Plus, Twitter e di seguaci su Twitter e Pinterest.

Tabella 5.1: Indici di correlazione e p-value dei test K-S

Sito	Numero di Utenti	Indice Di Correlazione	K-S p-value
Google Plus(amici)	72,271	0.9999	0.9794
Facebook(amici)	18,298	0.9996	0.9794
Twitter(amici)	78,225	0.9990	1.000
Twitter(seguaci)	78,225	0.9998	0.9895
Pinterest(seguaci)	39,586,033	0.9989	1.000
LiveJournal(amici)	4,307,491	0.9695	0.9895

indice di correlazione maggiore dello 0.9 e, su 21'135 casi analizzati, solo 170 lo hanno minore di 0.5, quindi meno dell'1%. È interessante considerare questi 170 account Twitter e verificare se svolgono attività sospette. Analizzandoli l'autrice scopre che solo 2 di loro sembrano utenti legittimi, mentre dei 168 rimanenti alcuni sono spam, ma la maggior parte fa parte di una rete di bot russi. Questi ultimi agiscono tutti allo stesso modo: seguono altri bot, postano una foto contenente frammenti di testi o citazioni e ne usano un'altra come foto profilo. La figura 5.3 mostra un esempio di come agiscono questi account. Il loro scopo non è ancora chiaro, ma l'aver scoperto questa rete permetterà di fare ulteriori accertamenti, e la ricerca è stata resa molto più semplice dall'uso della Legge di Benford.

5.1.4 Conclusioni

Considerando quanto appena detto possiamo concludere che, in assenza di forze esterne che influenzano il comportamento degli utenti, la legge di Benford si applica alle relazioni che si creano con i Social. Questo vale sia per i Social Network guardati come un'unica entità che per le reti create dai singoli utenti. L'unico caso in cui la validità della legge non è stata riscontrata può essere giustificato da una meccanismo di funzionamento che porta gli utenti a selezionare un numero specifico di interessi da seguire, rendendo quindi le loro scelte non arbitrarie.




Figura 5.2: Distribuzione delle prime cifre significative di seguiti su Pinterest




Figura 5.3: Esempio di tweet di bot russi

5.1.5 Applicazioni future

Considerando lo studio appena illustrato, possiamo concludere che la legge di Benford può essere impiegata come mezzo preliminare per individuare account fraudolenti, in quanto nella maggior parte dei casi in cui non viene rispettata ritroviamo delle attività sospette (come nel caso di Twitter). Specifichiamo *nella maggior parte dei casi* perché una deviazione dalla legge non implica necessariamente un problema, anzi sarebbe statisticamente improbabile non trovare nessun caso anomalo. Il discostarsi dalla Legge di Benford deve essere interpretato solo come un campanello d'allarme e va seguito da ulteriori verifiche che chiariscano da dove deriva il distacco dal modello previsto.


5.2 Covid-19

In questo capitolo vogliamo applicare la Legge di Benford ai dati dei contagi da Covid-19 in Italia, per verificare se in questo caso la distribuzione si comporta come ci aspettiamo. I dati analizzati provengono dal *Dipartimento della Protezione Civile*[7] e sono stati analizzati in un primo momento con SQLiteStudio e successivamente con Matlab, con il quale abbiamo creato i grafici per mettere le due curve a confronto.


In particolare abbiamo analizzato il numero di nuovi positivi giorno per giorno, in tre diversi lassi di tempo:

- per tutta la durata della pandemia, dal 24/02/2020 al 11/10/2021. I valori analizzati in questo caso sono 596.
- prima dell'inizio della campagna vaccinale, dal 24/02/2020 al 31/12/2020. I valori analizzati in questo caso sono 312.
- dopo l'inizio della campagna vaccinale, dal 01/01/2021 al 11/10/2020. I valori analizzati in questo caso sono 284.


Nel grafico 5.4(a) vengono messi a confronto i valori rilevati nel primo caso (ovvero considerando tutti i dati forniti) e quelli predetti dalla legge di Benford, mentre in 5.4(b) e 5.4(c) vengono confrontati con la legge di Benford, rispettivamente, i dati prima e dopo la campagna vaccinale.



(a) Valori reali e valori predetti a confronto: dati dal 24/02/2020 al 11/10/2021



(b) Valori reali e valori predetti a confronto: dati dal 24/02/2020 al 31/12/2020



(c) Valori reali e valori predetti a confronto: dati dal 31/12/2020 al 11/10/2021

Possiamo notare che, anche se non perfettamente, i valori rilevati seguono la legge di Benford in tutti e tre i casi. Il distacco potrebbe essere dovuto al fatto che i dati analizzati non sono abbastanza numerosi, infatti vediamo che l'aderenza peggiora quando consideriamo il caso prima e dopo il vaccino. Calcoliamo, limitandoci al primo caso, la probabilità discreta:

z	1	2	3	4	5	6	7	8	9
$p_Z(k)$	0.362	0.206	0.129	0.072	0.077	0.041	0.045	0.035	0.030

Confrontando i valori ottenuti con la legge di Benford discreta (3.5, a pagina 10), vediamo che l'errore massimo si verifica per $k = 1$, infatti la differenza tra le due probabilità in valore assoluto vale 0,061. Basandoci sul caso esaminato possiamo concludere che la legge di Benford si applica con buona approssimazione agli andamenti dei contagi da Covid-19 in Italia. Teniamo anche conto che i dati analizzati sono quelli relativi ai nuovi positivi dichiarati, quindi i numeri sono sottostimati rispetto ai nuovi positivi reali, e anche questo potrebbe concorrere alla non perfetta aderenza.

Bibliografia

- [1] D.E.Knuth, *The Art Of Computer Programming, Vol.2*, Third Edition (1998), Addison Wesley Longman,
- [2] Ralph A.Raimi, *The First Digit Problem*, American Mathematical Monthly 83 (1976): 521-538,
- [3] Q.Berger, F. Caravenna, P. Dai Pra *Probabilità. Un primo corso attraverso esempi, modelli e applicazioni*, Seconda Edizione, Springer (2021),
- [4] Jennifer Golbeck, *Benford's Law Applies to Online Social Network*, PLoS ONE 10(8): e0135169. <https://doi.org/10.1371/journal.pone.0135169>,
- [5] Andrea Burgos, Andrés Santos *The Newcomb-Benford law: Scale invariance and a simple Markov process based on it*, American Journal of Physics 89, 851-861 (2021) <https://doi.org/10.1119/10.0004957>,
- [6] A.M.Mood, F.A.Graybill, D.C.Boes, *Introduzione Alla Statistica*, McGraw-Hill (1991),
- [7] dati del *Dipartimento della Protezione Civile*, al link <https://github.com/pcm-dpc/COVID-19/blob/master/dati-andamento-nazionale/dpc-covid19-ita-andamento-nazionale.csv>